

# PRÁCTICA HADOOP


PROGRAMACIÓN CONCURRENTE Y DISTRIBUIDA










El primer paso es instalar una máquina virtual, en mi caso, instalé Orecle VM VirtualBox. Una vez instalada, y teniendo el archivo vmdk de Cloudera procedemos a instalarlo en la máquina virtual. (<a href="https://downloads.cloudera.com/demo">https://downloads.cloudera.com/demo</a> vm/virtualbox/cloudera-quickstart-vm-5.12.0-0-virtualbox.zip)














Una vez instalado, iniciamos el sistema de Cloudera.



Ya en Cloudera, abriremos eclipse y crearemos los scripts necesarios para realizar el map reduce en hadoop.

Primero crearemos el script que hará de mapper (WordCounterMapper.java):

```
The call force Andrew Storage Search Pages from Page And Page Andrew Storage Search Page Andrew Storag
```



Después el script que hará de reducer (WordCounterReducer):


```
The contract of the contract o
```

Y por último el driver donde estará ubicado el main(), en este controlaremos el Job correspondiente al mapreduce (WordCounterDriver):


```
Application for particular mapes and file applications of the partic
```



Una vez creados los scripts, deberemos abrir la consola de comandos para configurar hadoop. Empezaremos por crear una carpeta con nuestro usuario y darle permisos con -chow.



Después, buscaremos el texto al queremos aplicar map reduce (el quijote en este caso) y lo guardaremos en una carpeta local.





Una vez guardado, iremos al directorio donde se encuentre nuestro proyecto de ecplise desde la consola y haremos una build del proyecto llamada "wordcounter.jar.

Una vez creada la build, la ejecutaremos desde hadoop, pasando como parámetros el texto del quijote (previamente guardado en /user/somozadev/input) y el directorio destino donde queremos guardar el resultado del mapreduce (/user/somozadev/wordcounter/output).

```
[cloudera@quickstart Contador-palabras]$ sudo hadoop jar wordcounter.jar WordcounterDriver /user/somozadev/wordcounter/input /user/somozadev/wordcounter/output 21/05/22 12:20:38 INFO client.RMProxy: Connecting to ResourceManager at /0.0.0.0:0032
21/05/22 12:20:36 INFO input.FileInput/format: Total input paths to process; 12/05/22 12:20:31 INFO mapreduce.JobSubmitter: number of splits:1
21/05/22 12:20:39 INFO mapreduce.JobSubmitter: Submitted application application 1021500485680 0001
21/05/22 12:20:31 INFO mapreduce.Job: The url to track the job: http://quickstart.clouder=180882/proxy/application_1621590485680_0001
21/05/22 12:20:32 INFO mapreduce.Job: The url to track the job: http://quickstart.clouder=180882/proxy/application_1621590485680_0001
21/05/22 12:20:32 INFO mapreduce.Job: Job job 1621590485680_0001 running in uber mode: false
21/05/22 12:21:21 INFO mapreduce.Job: map 00% reduce 00%
21/05/22 12:21:22 INFO mapreduce.Job: map 100% reduce 100%
21/05/22 12:21:21 INFO mapreduce.Job: map 100% reduce 100%
21/05/22 12:21:41 INFO mapreduce.Job: Job job 1621590485680_0001 completed successfully
21/05/22 12:12:141 INFO mapreduce.Job: Counters: 40
File: Number of bytes read=1800407
File: Number of bytes read=1800407
File: Number of bytes read=210602
INFS: Number of bytes read=210602
INFS: Number of bytes read=210602
INFS: Number of read operations=0
INFS: Number of write operations=0
INFS: Numb
```



Y como se puede ver en la captura anterior, se ha realizado el mapreduce de forma correcta. Se conecta al resourcesManager, ejecuta el trabajo y empiezan los procesos de map y reduce. Dado que solo tenemos un único modo, los trabajos tienen que hacerse secuencialmente (se ve en la captura que primero se realizan el 0% de las tareas map y 0% de las tareas reduce. Luego pasa a 100% de tareas map y 0% de tareas reduce y finalmente 100% de cada). Es decir, se trata de una pseudo distribución.




Finalmente, para ver el output podemos usar el comando hadoop fs -cat con el directorio para ver el contenido.


```
File Edit View Search Terminal Help
zafio 2
zaga 9
zagal 7
zagala 1
zagalas 6
zagalejas
zagales 4
zaharea 1
zaheriendo
 zaneriendo
zahor 1
zahrda 1
zal 2
zaleas 1
zalemas 3
zamarro 1
zamora 1
zamorana
zamoranas
zamoranas
zamoranos
zampoas 1
zanahorias
zancadilla
zancajos
zancas 3
zanja 1
zanoguera
zapateadores
zapatear
zapateo 1
zapatero
zapatetas
zapatetas
zapatetas
   zamorana
 zapaticos
zapatilla
zapatillas
zapato 8
zapatos 14
zaque 3
zaques 2
zaquizam
zaragoza
zarandajas
                                                            1
21
4
1
 zarpasen
zarzas 3
zarzo 1
 zarzo
zarzo 1
zas 1
zelador 1
zeuxis 1
znganos 1
zoca 1
znganos 1
zoca 1
zocodover
zodacos 1
zolo 1
zoltans 1
zoltans 1
zonzorino
zopiro 1
zoraida 78
zoroastes
zorostrica
zorra 1
zorras 1
 zorruna
zuecos
zulema
zurrn 1
zuzaban 1
[cloudera@quickstart Contador-palabras]$
```



De todas formas, este output no se encuentra de manera local en nuestro equipo, para poder traerlo a nuestra máquina debemos ubicarlo en el servidor hadoop y usar hdfs dfs -get [directorio del output] [directorio donde se desee guardar en local].



O si se prefiere, acceder al hue en nuestro navegador (iniciando sesión con usr: cloudera y pass: cloudera) donde podemos acceder a los directorios hdfs y encontraremos de una manera visual





Finalmente, si se desearía volver a realizar la ejecución de la aplicación, se deberá eliminar el directorio de salida para que no haya problemas a la hora de sobreescribir en él.

[cloudera@quickstart ~]\$ sudo hadoop fs -rm -r -f /user/somozadev/wordcounter/ou tput Deleted /user/somozadev/wordcounter/output

[cloudera@quickstart ~]\$